

项目编号：

“有智青年”

本科生科创项目结题报告

课题名称 基于测序及深度学习的跨多种
脑疾病的预测与共性机制研究

申 请 人 吴皓玥 刘心亦

院 系 类脑智能科学与技术研究院

指导老师 陈靖祺

填表日期 2024/9/12

类脑智能科学与技术研究院制表

一、 课题信息

课题名称	基于测序及深度学习的跨多种脑疾病的预测与共性机制研究					
申请人	姓 名	吴皓玥	性别	女	学 号	21307110386
	院 系	计算机科学技术学院			专 业	计算机科学与技术
	长期固定电话	13957010342			手 机	13957010342
	常用电子邮箱	21307110386@m.fudan.edu.cn				
	姓 名	刘心亦	性别	女	学 号	22307110299
	院 系	生命科学学院			专 业	生物科学
	长期固定电话	13972263699			手 机	13972263699
	常用电子邮箱	22307110299@m.fudan.edu.cn				
导 师	姓 名	陈靖祺			工 号	39022
	院系单位(部门)	复旦大学类脑智能科学与技术研究院				
	联系电话	13818812566				
	电子邮箱	jingqichen@fudan.edu.cn				

二、 结题报告

类脑智能科学与技术研究院“有智青年”科创项目成果

基于测序及深度学习的跨多种脑疾病的 的预测与共性机制研究

作者： 吴皓玥、刘心亦

院系年级：2021 级 计算机科学技术学院、2022 级 生命科学学院

指导老师：陈靖祺

项目摘要：全基因组关联研究（GWAS）将人类基因组中的序列变异与普遍存在的性状联系起来，提高了我们探究神经精神疾病潜在遗传机制的能力。尽管大量研究已经发现与神经发育障碍和神经退行性疾病相关的蛋白质编码 DNA 变异，但对广泛的非蛋白质编码基因组区域中发生的功能性、调控性遗传变异的了解仍然有限。本项目以阿尔兹海默症为例，依托疾病及健康对照组全基因组关联及测序数据，重点研究非编码区基因变异对神经精神疾病遗传机制的贡献。基于已有的预训练序列语言模型预测序列变异的基因表达情况，构建分类模型判断疾病是否发生。项目的结果将有助于加深对疾病机制的认识，并后续扩展至对多种脑疾病机制共性的研究。

关键词：非编码变异、脑疾病、多模态、深度学习

Abstract: Genome-wide association studies (GWAS) have linked sequence variations in the human genome to prevalent traits, enhancing our ability to explore the underlying genetic mechanisms of neuropsychiatric disorders. Although numerous studies have identified variants in protein-coding DNA associated with neurodevelopmental and neurodegenerative diseases, there is still limited understanding of the functional and regulatory genetic variations occurring in extensive non-coding regions of the genome. This project focuses on Alzheimer's disease as a model to investigate the contribution of non-coding genetic variants to the genetic architecture of neuropsychiatric disorders, using whole-genome association and sequencing data from both Alzheimer's patients and healthy controls. By leveraging pre-trained sequence language models to predict the impact of sequence variations on gene expression, we aim to develop a classification model capable of assessing disease risk. The findings from this study are expected to enhance our understanding of disease mechanisms and provide a basis for exploring shared genetic mechanisms across multiple brain disorders.

Key Words: non-coding variants, brain disorders, multi-omics, deep learning

目录

项目摘要	3
第一章 绪论	5
1.1 引言	5
1.2 脑疾病遗传机制	5
1.3 基因组非编码区变异	5
1.4 基因表达预测模型 Enformer	6
1.5 跨疾病多模态研究目的与意义	6
第二章 计划执行概述	7
2.1 研究计划完成情况	7
2.1.1 发掘疾病相关非编码变异	7
2.1.2 利用 Enformer 模型预测结果建立疾病分类模型	7
2.2 研究内容变动说明	8
2.2.1 罕见疾病相关 SV(包含串联重复变异)的确定	8
2.2.2 跨疾病共性机制研究	8
第三章 进展与结果	9
3.1 多脑区染色质可及性数据分析	9
3.2 AD 显著关联 SNP-增强子-基因通路	11
3.2.1 表达分析	11
3.2.2 通路富集	12
3.3 使用 Enformer 预测的结果建立 ClinVar 公共数据集变异数据的分类模型	15
3.3.1 ClinVar 公共数据集分析与处理	15
3.3.2 分类模型建立与结果分析	16
3.4 使用 Enformer 预测的结果建立个体阿尔兹海默症的疾病分类模型	16
3.4.1 个体数据分析与处理	16
3.4.2 分类模型建立与结果分析	18

第一章 绪论

1.1 引言

随着全球人口老龄化和各种社会压力的加剧，精神疾病、神经系统疾病以及物质使用障碍等脑疾病正在成为世界各国面临的共同挑战。据估计，全世界大约每 100 个儿童中就有一人患孤独症（ASD）；在中国，孤独症患者已超 1300 万人（2023 年），并以每年近 20 万的速度增长。据世界卫生组织（WHO）统计，全球约有 5% 的成年人患有抑郁症，每 40 秒就有一人因抑郁自杀而失去生命。超过 5500 万人（65 岁以上的人群中，8.1% 的女性和 5.4% 的男性）患有阿尔兹海默症（AD），估计这一数字到 2030 年时将上升到 7800 万人，到 2050 年时则将达到 1.39 亿人。这些神经精神疾病的遗传机制尚不够清晰，除已被广泛研究的基因编码区变异外，现有研究认为非编码区变异可能会对其有显著贡献。

本项目依托张江国际脑库疾病队列的全基因组测序数据，重点研究基因组非编码变异对阿尔兹海默症遗传机制的贡献。确定治病变异的潜在靶基因以及用序列预训练语言模型解读变异的分子功能后果，将为后续的机制探索与临床研究提供新的靶点。

1.2 脑疾病遗传机制^[1]

在基因层面，由于脑疾病脑认知普遍具有遗传性的特点，因此遗传数据是我们研究脑疾病的重要手段。经过几十年的发展，世界各地已积累了海量的脑疾病遗传数据^[2]，这些遗传大数据对于揭示脑疾病的遗传机制具有重要意义。

在分子层面，艾伦脑科学研究所（Allen Institute for BrainScience）发布了首个人脑基因表达数据，详细刻画了每个基因在全脑表达的数据（The Allen Human Brain Atlas），使得我们能够探索人脑各区域脑功能实现的分子遗传基础^[3]。

1.3 基因组非编码区变异

近年来全基因组关联研究（Genome-Wide Association Studies）已发现较多与发育型精神疾病相关的遗传变异处在基因组非编码区。精神疾病相关遗传变异中存在大量非编码变异，且分子组学信息可能帮助理解非编码变异在精神疾病中的病因相关调控机制

^[4]。

指导老师研究团队通过 GWAS 识别的调控性 SNP 破坏的远程基因调控来探索 14 种神经精神疾病之间的共享组织特异性，揭示了基因非编码区变异对神经疾病的调控通路^[5]。总体来看，非编码变异目前的探索还比较有限，有待进一步研究。

1.4 基因表达预测模型 Enformer

Žiga Avsec 教授团队与 Calico 的团队共同开发了一种基于 Transformers 的神经网络架构 Enformer^[6]，它能够整合来自基因组中远程交互（高达 100 kb 远）的信息，大大提高了从 DNA 序列预测基因表达的准确性，可以用于解释来自全基因组关联研究的疾病相关变异，此外，Enformer 还学会了从 DNA 序列直接预测增强子-启动子的相互作用。

1.5 跨疾病多模态研究目的与意义

精神疾病的遗传机制复杂，往往难以用单基因变异解释，是多种遗传变异的累积效应，且疾病之间共享一些表型症状、共病率较高，提示存在一些共享的病因机制。由复旦大学类脑智能科学与技术研究院领衔的张江国际脑库目前正在建设之中，按照“三库（干库、湿库、算法库）融合，多源共享”的建设思路和“全维度、多模态、跨时空”的数据获取模式，围绕精神分裂症、抑郁症、自闭症、脑卒中、精神退行性疾病以及大学生人群等六个队列，采集环境、行为、遗传、脑影像、神经等多尺度数据。通过对这些数据的分析与深度挖掘，有望对神经精神疾病的分子机制与共病现象有更深入的理解。

第二章 计划执行概述

2.1 研究计划与目标

2.1.1 发掘疾病相关非编码变异的调控靶基因

在指导老师课题组脑疾病整体研究框架“variant-gene-disease”下，本项目成员主要承担探索脑区样本中 variant-gene pairs 的任务。首先通过阅读文献找到合适的分析方法，在输入数据、输出格式、参数设置以及准确率等维度比较后选择 ABC (Activity-by-contrast) 计算工具，得到各脑区的基因调控情况。接下来寻找不同脑区的染色质可及性 (accessibility) 数据和染色质区域接触 (contact) 数据，选择了 21 个组织的 DNase-seq 或 ATAC-seq，转换成 ABC 接受的输入格式，从而得到各个组织中的增强子区域和对应的靶基因以及一个表征增强子-基因调控相互作用强弱的分数。

利用 ABC 初步结果中的 prediction，进行后续的统计和可视化处理。第一，为了查看与阿尔兹海默症显著关联的基因的增强子情况，从文献中找到 107 个 AD 风险基因，统计它们在不同组织样本中对应的增强子 ABC 分数。第二，GWAS Catalog 下载阿尔茨海默症显著关联 SNP，与 ABC prediction 中增强子区域做 overlapping 分析，进一步对应到基因。借助 GTEx 网站数据，得到相关基因在各组织以及不同脑区发育阶段的表达差异情况。最后，进行 Go 富集分析，前景基因为上述 SNP-enhancer-gene 通路确定的基因，得到这组基因在生物功能或疾病机制中的可能作用。

2.1.2 利用 Enformer 模型预测结果建立疾病分类模型

对 ClinVar 公共数据集的数据进行初步筛选和处理，从 ClinVar38 和 GRCh38 参考基因组中提取以单核苷酸多态性 (SNP) 为中心的参考序列和替代序列。将这些序列作为 Enformer 模型的输入，获得初步的基因表达数据。随后，利用主成分分析 (PCA) 等降维方法对数据进行探索性分析，最后通过机器学习算法构建分类模型。

从张江脑库中收集的 988 位个体的疾病表型信息中，筛选出阿尔茨海默症患者和正常对照组。对于每位个体，从 184 个与阿尔茨海默症相关罕见变异所在基因的转录起始位点 (TSS) 中提取基因序列，每条序列涵盖上下游 1,322,268 个碱基对范围内的单核苷酸变异 (SNV) 信息。这些序列作为 Enformer 模型的输入，获得每位个体的初步基因表达数据，并用于后续个体分类模型的构建。在数据分析阶段，首先通过计算相关系数来

评估不同个体之间的相关性，利用箱型图等可视化工具深入分析数据分布。基于这些分析结果，采用多种机器学习算法进行模型训练，并最终结合循环神经网络（RNN）设计个体分类模型，用于区分阿尔茨海默症患者与正常对照组。

2.2 研究内容变动说明

2.2.1 罕见疾病相关 SV（包含串联重复变异）的确定

开题计划中，希望采用长短读测序结合的方法，识别和定位基因组中的串联重复序列（TR）的基因型。但由于队列级别 SV 计算对计算资源要求高、耗时太长，在本项目开展期间这一前期数据未能及时获取；通过文献学习和与老师多次沟通，我们找到了更可行的方向，即首先聚焦 AD-associated SNPs 及本地队列发现的 AD 罕见 SNP，结合我们的增强子-基因调控对数据，聚焦于解释阿尔兹海默症中潜在风险变异的 variant-gene-disease 通路。这一结果后续可推广应用于队列级别 SV 的解读。

2.2.2 跨疾病共性机制研究

脑疾病的遗传机制复杂，往往是多种遗传变异的累积效应且疾病之间共享一些表型症状，可能存在一些共享的病因机制。由于项目时间有限，我们目前以前期数据较为完善的阿尔兹海默症为例，建立了 variant-gene-pathway 的环路，并探索了基于 variant-gene expression 预训练预测结果的疾病分类模型的可行性。本项目的结果将为后续开展跨多种脑疾病的共性机制研究提供前期基础。

第三章 进展与结果

3.1 多脑区染色质可及性数据分析

Activity-by-Contact (ABC) 模型可预测在特定细胞类型的基础上增强子与基因的调控关系，接受可及性数据 (DNase-seq 或 ATAC-seq)，以及接触数据 (Hi-C)，通过寻找并筛选峰值、估算增强子活动性、计算增强子-启动子接触性等步骤，输出包含增强子-基因以及相应 ABC 分数的结果文件。

本试验中选择 21 个不同脑区数据。21 块组织样本中包含阿尔兹海默症病理直接相关区域，比如海马体，杏仁核，脑周细胞；也包括一些潜在关联的脑高级功能区，比如额叶和顶叶；还有一些与阿尔兹海默症关联不明显但与其他退行性神经疾病相关脑区，比如帕金森患者中受损的基底核，这些区域可作为对照。输入数据的纳入标准详见 data_preparation [\(supplementary table\)](#)。

运行得到结果，即 21 个脑区中显著的 enhancer-gene 对信息。关于输出的详细说明见 result_explanation，结果初步统计见 statistics [\(supplementary table\)](#)。




图1 21 个脑区中全 23 条染色体增强子-基因对数量统计

为了增强对于这个初步结果的理解，从文献^[6]中找到 107 个研究较为透彻的阿尔兹海默症相关基因，统计了它们在不同组织样本中对应的增强子的相应最大 ABC 分数，结果如下。ABC 分数越大，说明增强子-基因调控相互作用越强。




图2 阿尔兹海默症相关基因在 21 个脑区中对应增强子调控强度

3.2 AD 显著关联 SNP-增强子-基因通路

为了进一步利用已有数据探索阿尔兹海默症潜在风险基因，从 GWAS Catalog(<https://www.ebi.ac.uk/gwas/home>) 获取 AD 显著关联 SNP，取不在基因上 (intergenic) 且与每个组织中找到的增强子有交集者，并筛除疾病无关性状 (如发病时间与用药情况)，找到 enhancer 对应的基因共 80 个，进而得到其在各组织以及不同脑区发育阶段的表达差异情况与功能富集结果。

3.2.1 表达分析

借助 FUMA 网站(<https://fuma.ctglab.nl/>)，观察所得 80 个目标基因在不同组织中表达情况，以及在脑的不同发育阶段表达情况。重点关注其他组织中表达水平一般而在各个脑组织中高表达的基因，这些基因更可能与 AD 病理发展有关。其中最显著的一个是 *CTNND2*，该基因编码一种黏附连接相关的蛋白，属于 armadillo/ β -catenin 超家族，在神经系统发育中扮演着重要的角色，尤其与神经突触和细胞间的黏附相关。推测该基因通过影响神经元之间的黏附连接作用于突触可塑性，从而影响学习与记忆功能。




图3 目标基因在不同人体组织中的表达强度




图4 目标基因在不同脑发育阶段中的表达强度

3.2.2 通路富集

我们接下来进行了 GO 基因功能富集分析，将所得 80 个基因作为目标基因，试图找出它们所富集的生物通路，从而推断这组基因在生物功能或疾病机制中的可能作用。富集 P 值应该进行多重检验校正 multi-test adjustment，如 FDR，取 adjusted P-value < 0.05 为显著富集的通路。




图 5 GO enrich 结果气泡图 (Biological Process)




图 6 GO enrich 通路结果 (Biological Process)

经检查, molecular function 与 cellular components 得到的通路多为基本代谢所需结构或功能, 并无明显特异性。而 biological process 部分富集通路在免疫反应中得到了较显著结果(图 6 所示)。Mucosal immune response (GO:0002385, adjust P = 9.15×10^{-8}) 是一种发生在黏膜组织中的免疫反应; 其子过程 Innate immune response in mucosa (GO:0002227, adjust P = 1.45×10^{-8}) 是黏膜组织中发生的先天免疫反应的过程。由 Antimicrobial humoral response (GO:0019730, adjust P = 6.76×10^{-6}) 指向两条体液免疫通路, 分别是抗菌肽介导的抗菌体液免疫反应与体液介导的针对细菌的免疫反应。此外, 针对真菌 (GO:0050832, adjust P = 9.58×10^{-7}) 和革兰氏阴性菌 (GO:0050829, adjust P = 1.21×10^{-5}) 的细胞防御也得到了富集。考虑到神经炎症反应中小胶质细胞和星形胶质细胞的活化在阿尔兹海默症发病与发展过程中的作用, 以及外周炎症通过血脑屏障激活中枢神经系统的免疫反应的潜在可能, 免疫相关通路对 AD 病理的研究有重要意义。

尝试过扩大增强子范围来增大基因数量, 但是在 $\pm 2\text{Kb}$ 的条件下仍然只寻找到 80 个; 若进一步加大, 可能导致寻找到的基因准确率下降, 实际上我们认为 4Kb 的范围可能已经导致了一些错误率。

最后, 结合 SNP-enhancer-gene 通路中对应出的 ABC 分数, 绘制 80 个基因在 21 个组织中的调控强度图。ABC Score 为 1 的增强子即为自我调控的启动子。可以看出 *USP10*, *ANGPT4*, *LMOD3*, *FAM83E* 的调控通路及较强; 其中 *USP10* 编码泛素相关酶, *FAM83E* 可能在 MAPK 信号转导中起作用, 属于普遍的生物功能; *LMOD3* 对于骨骼肌中肌动蛋白的组织至关重要; 而 *ANGPT4* 编码的血管生成素是在血管生成和发育过程中发挥作用的蛋白质, 它们调节内皮细胞与支持血管周围细胞的相互作用。猜测 *ANGPT4* 基因的功能改变可能会通过影响血脑屏障的正常功能, 影响到阿尔兹海默症的疾病进程。

值得注意的是, 上述结论都是基于正常个体数据分析的推测, 后续还需要进一步的病患数据比对以及生物实验的验证。




图7 目标基因结合 ABC Score 统计结果

3.3 使用 Enformer 预测的结果建立 ClinVar 公共数据集变异数据的分类模型

3.3.1 ClinVar 公共数据集分析与处理

ClinVar 公共数据集收录了大量不同类型的遗传变异（如单核苷酸变异、插入、缺失等）与多种人类疾病的关联。这些变异由不同的提交者（包括研究机构、实验室和诊断公司）提供，并经过临床验证或预测。每个变异在 ClinVar 中都附有其临床意义的标签，包括以下几类：致病（Pathogenic）、很可能致病（Likely pathogenic）、临床意义未明（Uncertain significance）、很可能良性（Likely benign）、良性（Benign）、与药物反应相关（Drug response）、与其他表型相关（Other）。观察图 10 可知 ClinVar 数据集中大部分的数据的标签为“Uncertain significance”，这个对于分类模型的训练没有太大的帮助，因此我们从中选出 1,083,492 个标签为“Benign”和 262,228 个标签为“Pathogenic”的数据，在此基础上，随机抽取出 8000 个数据作为训练集，1000 个数据作为测试集，在抽取数据的同时尽量保证标签分布平衡。




图8 ClinVar 公共数据集标签分布

首先通过 `variant_centered_sequences` 函数从 ClinVar38 和 GRCh38 中提取变异位点的参考序列和替代序列 (Reference Sequence 和 Alternative Sequence)，然后将这些序列输入到 Enformer 模型中进行预测。每条序列的输出将包含 896 个位置上对应的 5313 个 track 的结果。

由于每个 track 的值可能存在数量级上的差异，这可能会对后续的分类任务产生影响。因此，首先对数据进行归一化处理，以确保所有 track 的值在相同的量级范围内，从而减少这些差异对分类模型性能的干扰。

同时，由于输入数据的维度较大，在建立分类模型的过程中使用了以下输入数据处理方法：

- 使用中心变异位点的 track 值。
- 使用中心变异位点的 track 值和参考 track 值。
- 使用中心变异位点的 track 值与参考 track 值的差值。
- 计算以变异位点为中心的每个位点周围 n 个位置的 track 值的统计特征，如平均值、标准差、最大值等（其中 n 为考虑的位点数量）。

通过这些方法可以帮助更好地处理和分析大维度输入数据，加快训练速度。

下图展示了不同处理方法下的输入数据在 PCA 空间中的分布结果。




图9 165个位点的最大值分布（左）65个位点的标准差分布（中）165个位点的平均值分布（右）

3.3.2 分类模型建立与结果分析

考虑到输入数据的维度非常大，选择了朴素贝叶斯算法、决策树算法和随机森林算法作为分类模型。朴素贝叶斯算法由于其计算效率高且适用于大规模数据集，能够在特征之间独立性假设较为合理的情况下提供有效的分类结果。决策树算法通过递归地划分数据集来处理高维数据，并且具有较好的解释性和灵活性。随机森林算法则通过集成多棵决策树来提高模型的鲁棒性和准确性，特别是在减少过拟合方面表现出色。这些算法在处理高维数据时各自具有不同的优势，从而帮助提升模型的整体性能。

通过改变不同形式的输入参数值，并采用多种分类模型进行实验，我们可以获得如下的准确率结果。

	GaussianNB	DecisionTreeClassif	RandomForest
变异点归一化后中心值 Alt	0.45	0.529375	0.55125
变异点归一化后中心值 Alt-Ref	0.455625	0.50875	0.55875
平均值Alt	0.4675	0.52875	0.56875
中心值附近65个值平均值Alt-Ref	0.455625	0.5175	0.5425
中心值附近65个值标准差Alt	0.46875	0.5475	0.555625
中心值附近65个值标准差Alt-Ref	0.469375	0.508125	0.55875
中心值附近165个值最大值Alt	0.473125	0.500625	0.57
中心值附近165个值最大值Alt-Ref	0.4825	0.529375	0.554375
中心值附近165个值平均值Alt	0.465	0.52	0.585625
中心值附近165个值平均值Alt-Ref	0.5275	0.513125	0.546875
中心值附近165个值标准差Alt	0.46625	0.524375	0.571875
中心值附近165个值标准差Alt-Ref	0.471875	0.51125	0.561875

图10 基于 ClinVar 公共数据集建立分类模型的准确率

在得到上述结果后，我们发现模型的预测准确率仅在 0.45 至 0.6 之间，远低于预期的分类模型准确率目标。经过分析，可能的原因包括以下两点：ClinVar 数据集中包含许多与罕见疾病相关的变异，由于 Enformer 模型在预训练过程中学习的主要是常见变异对应的序列语法，导致其在预测这些罕见变异时效果不佳；ClinVar 数据集涵盖了多种不同的疾病类型，这种多样性增加了分类任务的复杂性。要有效捕捉并学习这种复杂多样的变

异信息，可能需要更大规模的数据集以及更加复杂和针对性的模型架构，才能在分类任务中取得更好的预测效果。

3.4 使用 Enformer 预测的结果建立个体阿尔兹海默症的疾病分类模型

3.4.1 个体数据分析与处理

张江脑库提供的数据集中包含 988 位个体的疾病表型信息，个体分为不同的表型类别。其中，有 239 位阿尔茨海默症患者和 136 位正常对照组。每个个体的数据包含 184 个与阿尔茨海默症相关的转录起始位点（TSS），每个 TSS 为中心，覆盖上下游 1,322,268 个碱基对范围内的单核苷酸变异（SNV），从而得到一条基因序列。因此，每位个体的 184 条基因序列作为 Enformer 模型的输入。模型输出的结果与参考序列的输出相减，最终为每位个体生成一个大小为（184, 896, 5313）的结果矩阵，用于后续的分析 and 模型训练。

从 5313 个序列中筛选出与脑神经相关的 track，最终保留 83 个 track，因此输入数据维度减少为（184, 896, 83）的矩阵。

DNASE:cerebellum male adult (27 years) and male adult (35 years)
DNASE:frontal cortex male adult (27 years) and male adult (35 years)
DNASE:frontal cortex female adult (67 years) and female adult (80 years)
DNASE:middle frontal gyrus male adult (78 years)
DNASE:cerebellar cortex male adult (78 years) and male adult (84 years)
DNASE:midbrain male adult (78 years) and male adult (84 years)
DNASE:pons male adult (78 years)
DNASE:occipital lobe male adult (84 years)
DNASE:inferior parietal cortex male adult (84 years)
CHIP:H3K27ac:temporal lobe male adult (81 years)
CHIP:H3K4me1:layer of hippocampus male adult (81 years)

图 11 筛选出的部分 track 描述

使用热力图展示个体输入值的大小，可以观察到不同 track 之间数值相差较大，需要进行归一化处理。




图 12 ZIB_0001_AD 个体的 Enformer 模型预测值与参考基因组预测值对比




图 13 ZIB_0007_NC 个体的 Enformer 模型预测值与参考基因组预测值对比

使用箱型图分析同一 track 上数据分布，可以发现相同 track 上存在比较多的极值，在之后考虑使用一些方法来处理极值。




图 14 track11 至 track20 的数据分布箱型图




图 15 track11 至 track20 数据绝对值分布箱型图

对于分类使用到的 286 个个体的数据都相互求得相关系数，其中前 150 位为阿尔兹海默症患者，后 136 位为正常对照组。观察相关系数热力图发现大部分人的数据相关系数都在 0.6-0.85 之间，阿尔兹海默症患者与正常对照组并没有显著的区别，因此分类时需要考虑使用更复杂的方法来实现。




图 16 个体之间相关系数热力图

3.4.2 个体分类模型建立与结果分析

同样使用朴素贝叶斯、决策树、随机森林算法，在一定范围内找到最佳参数，但是分类的准确率始终在 0.45–0.6 之间。

a. 高斯朴素贝叶斯 (GNB)

测试集准确率：56.90%

b. 决策树分类器 (DecisionTreeClassifier)

交叉验证最佳准确率：59.65%

训练集准确率：71.05%

测试集准确率：53.45%

c. 随机森林分类器 (RandomForestClassifier)

交叉验证最佳准确率：54.39%

训练集准确率：85.96%

测试集准确率：48.28%

根据数据的特性，考虑使用循环神经网络，可以将不同的 track 视为图像的不同通道，其中 184 条序列对应图像的高度，896 个位点对应图像的宽度。因此，可以将循环神经网络应用于这一分类任务中。经过不断调试，使用包含两层卷积层和两层全连接层的循环神

神经网络可以在训练过程中大大降低训练集的损失率，但同时测试集的准确率也在下降。




图 17 循环神经网络训练损失率和测试准确率随训练轮数变化情况

机器学习算法和循环神经网络都没有达到很好的效果，模型表现不佳的原因可能在于输入数据的复杂性过高，机器学习算法难以提取有效的分类特征。数据中存在高维度、多样性或噪声，使得算法难以学习到具有代表性的模式，从而无法显著提升准确率。对于神经网络而言，训练数据样本量过小，导致模型即使在最简单的结构下也容易出现过拟合现象。由于样本量不足，模型倾向于记住训练集中的噪声和特定模式，而不是学习到具有泛化能力的特征，最终在测试集上的性能下降，无法有效处理未见过的数据。此外，Enformer模型训练数据主要是常见变异，我们经常反复测试仍无法提升效果，提示常见与罕见变异的语法语义存在较大差别，罕见变异对基因表达的预测可能需要新的模型来实现。

参考文献

[1] 程炜等. "基于多尺度多模态数据的脑疾病研究进展——遗传影像大数据研究." 中国科学基金 (2021).

[2] Zhao, Bingxin et al. "Genome-wide association analysis of 19,629 individuals identifies variants influencing regional brain volumes and refines their genetic co-architecture with cognitive and mental health traits." *Nature genetics* 51.11 (2019): 1637–1644.

[3] Shen, Elaine H., Caroline C. Overly, and Allan R. Jones. "The Allen Human Brain Atlas: Comprehensive gene expression mapping of the human brain." *Trends in neurosciences (Regular ed.)* 35.12 (2012): 711–714.

[4] Sullivan, Patrick F., and Daniel H. Geschwind. "Defining the Genetic, Genomic, Cellular, and Diagnostic Architectures of Psychiatric Disorders." *Cell* 177.1 (2019): 162–183.

[5] Chen, Jingqi et al. "Disrupted long-range gene regulations elucidate shared tissue-specific mechanisms of neuropsychiatric disorders." *Molecular psychiatry* 27.6 (2022): 2720–2730.

[6] Avsec, Ž., et al., Effective gene expression prediction from sequence by integrating long-range interactions. *Nat Methods*, 2021. 18(10): p. 1196-1203.

[7] Jansen, I. E., Savage, J. E., Watanabe, K., Bryois, J., Williams, D. M., Steinberg, S., ... & Posthuma, D. (2019). Genome-wide meta-analysis identifies new loci and functional pathways influencing Alzheimer's disease risk. *Nature genetics*, 51(3), 404-413.

三、 指导教师评语

两位同学在本项目框架下，结合各自的专业所长，进行了刻苦高效的科研实践学习，为今后的科研之路打下了坚实的基础。吴皓玥是计算机专业学生，原本没有生物学基础，在参加本项目过程中从 0 学习了基因组变异机制、脑疾病与脑区等生物学知识；刘心亦同学为生物学专业学生，参加本项目后从 0 自学了编程、数据处理、制图等技术。两位同学都在较短时间内克服了跨学科困难，顺利进入到生物-信息交叉学科研究之中，是十分值得称赞的。两位同学分两个相互关联的子方向，以阿尔茨海默症为例，对本项目展开了深入细致的探索，分别取得了一定前期结果，为后期项目的进一步开展提供了良好的基础。本项目时间较为短暂，两位同学能在有限时间内、在大二大三的繁多专业课压力中，克服困难、不畏繁琐，完成目前所得的结果，我认为实属不易。希望短暂时光中所习得的科研知识与技能，能帮助到两位同学今后的科研、学业道路。

指导教师：

年 月 日

四、 评审意见表

基本 评定	课题完成情况： ☐ 按计划完成，取得预期成果 ☐ 基本完成，但是与预期目标 尚有差距 ☐ 未达到预期目标	成果的创新性： ☐ 很好 ☐ 较好 ☐ 一般 ☐ 没有创新之处
	报告书写学术规范： ☐ 符合学术规范 ☐ 规范稍显不足 ☐ 与学术规范有较大差距 ☐ 完全不符合学术规范	成果发表情况： ☐ 已发表论文 ☐ 建议整理投稿发表 ☐ 成果尚未达到发表水平
综合 评价 与 建议		
	☐优秀 ☐良好 ☐合格 ☐不合格 评审老师： 年 月 日	

